

Démo 1 : assemblage de fragments génomiques

La plus petite superchaîne commune et les algorithmes
gloutons

Émeric Laberge

IFT3295, vendredi 11 septembre 2026

1. Accroche : pourquoi l'assemblage
2. Formaliser : SCS, chevauchement, GREEDY
3. L'exemple du papier, en interactif
4. GREEDY / MGREEDY / TGREEDY

Le séquenceur ne lit pas un génome

- Un séquenceur ne sort **jamais** un chromosome d'un bloc : des **centaines de milliers de courts fragments** (lectures), positions inconnues.
- Reconstruire le génome = **recoller** ces fragments : **l'assemblage**.




7 lectures ; en vrai, des millions

Le séquenceur ne lit pas un génome

- Un séquenceur ne sort **jamais** un chromosome d'un bloc : des **centaines de milliers de courts fragments** (lectures), positions inconnues.
- Reconstruire le génome = **recoller** ces fragments : **l'assemblage**.



7 lectures ; en vrai, des millions



les 7 lectures se recouvrent : une seule séquence de **39** caractères

Formaliser : la plus petite superchaîne commune (SCS)

Problème SCS


Étant donné $s_1, \dots, s_m$, trouver la plus courte chaîne s telle que chaque s_i apparaisse dans s comme **bloc consécutif** (sous-chaîne).

- NP-difficile (Gallant, Maier & Storer, 1980)
- Modélise l'assemblage : s_i = une lecture, s = le génome reconstruit (et la compression de données : LZ n'est pas loin).

Le chevauchement

Chevauchement et fusion

$chev(s, t)$ = longueur du plus grand **suffixe** de s qui est aussi un **préfixe** de t . Fusion $s \odot t$: longueur $|s| + |t| - chev(s, t)$.



- L'ordre compte : dans l'autre sens, $chev(t, s) = 0$.
- Piège : **auto-chevauchement**, $chev(\text{ATATAT}, \text{ATATAT}) = 4$, pas 6 : le cas trivial $k = |s|$ est exclu, sinon $chev(s, s) = |s|$ toujours.

L'algorithme utilisé en pratique : GREEDY

GREEDY

```
1 :  $S \leftarrow$  éliminer de  $S$  toute chaîne contenue dans une autre      ▷ SPG,
   l'optimum ne change pas
2 : tant que  $|S| > 1$  faire
3 :    $(s, t) \leftarrow \operatorname{argmax} \{ chev(s, t) : s, t \in S, s \neq t \}$   ▷ bris d'égalité
   arbitraire
4 :    $S \leftarrow (S \setminus \{s, t\}) \cup \{s \odot t\}$                     ▷ fusion :
    $|s \odot t| = |s| + |t| - chev(s, t)$ 
5 : fin tant que
6 : retourner l'unique chaîne restante
```

- Utilisé en séquençage et en compression de données depuis les années 80.

« **Alf ate half lethal alpha alfalfa** »

- `alf` est une sous-chaîne de `half` et `alfalfa` : toute superchaîne les contenant contient déjà `alf` → éliminé, **l'optimum ne change pas**.
- Reste $S_0 = \{\text{ate, half, lethal, alpha, alfalfa}\}$.
- Concaténation brute : $3 + 4 + 6 + 5 + 7 = \mathbf{25}$ caractères.

Tableau des chevauchements de S_0

Lecture : en **ligne** : s , dont on prend le **suffixe** ; en **colonne** : t , dont on prend le **préfixe**. Exemple : cellule (lethal, half) = 3.

$chev(s, t)$ (suffixe \ préfixe)	ate	half	lethal	alpha	alfalfa
ate	×	0	0	0	0
half	0	×	0	0	3
lethal	0	3	×	2	2
alpha	1	2	0	×	1
alfalfa	1	0	0	1	×

- Maximum = 3 : lethal $\rightarrow$ half et half $\rightarrow$ alfalfa.
- Et alf, éliminé ? Il revient gratuitement : c'est le chevauchement half $\rightarrow$ alfalfa (suffixe alf).
- Ligne ate : que des zéros, pourtant deux 1 dans la *colonne* ate : l'ordre compte.

Le chevauchement n'est pas symétrique

Il est important de noter que le chevauchement de deux séquences s_1 et s_2 fournissant le **suffixe**, s_2 le **préfixe** n'est **pas symétrique** : $chev(s_1, s_2) \neq chev(s_2, s_1)$ en général.

l	e	t	h	a	l
---	---	---	---	---	---

$$chev(lethal, half) = 3$$

h	a	l	f
---	---	---	---

h	a	l	f
---	---	---	---


$$chev(half, lethal) = 0$$

$\neq$

l	e	t	h	a	l
---	---	---	---	---	---

- Dans un sens, le suffixe `hal` recopie le préfixe `hal` ; dans l'autre, le `f` final ne figure même pas dans `lethal`.
- Donc $lethal \odot half = lethalf (7) \neq half \odot lethal = halflethal (10)$.

GREEDY pas à pas sur S_0



égalité à trois ($chev = 1$, trois choix) :

(1) $\alpha \odot ate = alphate$, puis $lethalfalfa \odot alphate \Rightarrow 17 \checkmark$

(2) $lethalfalfa \odot \alpha = lethalfalfalpha$, puis $\odot ate \Rightarrow 17 \checkmark$

(3) $lethalfalfa \odot ate = lethalfalfate \Rightarrow 18 \times$

le a final est absorbé dans ...ate : plus rien ne recolle avec alpha

- Optimum : **17**. Deux choix de l'égalité y mènent ; le troisième donne **18** (le papier : « un caractère de plus »). Le **bris d'égalité** décide donc du résultat.

Trois gloutons

Ici $OPT = |SCS(S)|$.

- **GREEDY** : $\leq 4 \cdot OPT$; fusionne la paire **distincte** de chevauchement max.
- **MGREEDY** : $\leq 4 \cdot OPT$; si le max est une chaîne avec **elle-même**, elle est mise de côté dans T .
- **TGREEDY** : $\leq 3 \cdot OPT$; puis GREEDY sur T .

MGREEDY retire les chaînes auto-chevauchantes de l'ensemble ;
TGREEDY récupère la compression mise de côté.

Quand le chevauchement maximal est (s, s)

Contre-exemple du papier (p. 11), $m = 5$: $S = \{ca^5, a^6c^5, c^5b^6, b^5c\}$ et $s = b^6a^6$ (12 caractères).

sans s $\boxed{ca^5} \xrightarrow{5} \boxed{a^6c^5} \xrightarrow{5} \boxed{c^5b^6} \xrightarrow{5} \boxed{b^5c} \Rightarrow 19$

avec s $\boxed{b^5c} \xrightarrow{1} \boxed{ca^5} \xrightarrow{-0} \boxed{c^5b^6} \xrightarrow{6} \boxed{b^6a^6} \xrightarrow{6} \boxed{a^6c^5} \Rightarrow 33$

- Ajouter s (+12 caractères) allonge le résultat de **14** : les ponts a^6c^5 et c^5b^6 se fixent à ses extrémités ($6 > 5$) au lieu d'enchaîner S .
- Pire : chaque fusion recrée une chaîne à auto-chevauchement ($c^5b^6a^6c^5$) qui re-fusionne. L'emboîtement a une profondeur **arbitraire** (p. 11) et l'induction $\text{GREEDY}(S \cup \{s\}) \leq \text{GREEDY}(S) + |s|$ est **fausse**.
- D'où la règle de MGREEDY : quand $\text{argmax} = (s, s)$, s est déplacée vers T , ce qui coupe l'emboîtement (diapositive suivante).

MGREEDY : la procédure

MGREEDY (Blum et al., section 3)

```
1 :  $T \leftarrow \emptyset$ 
2 : tant que  $S \neq \emptyset$  faire
3 :    $(s, t) \leftarrow \operatorname{argmax} \{ \text{chev}(s, t) : s, t \in S \}$    ▷  $s, t$  pas forcément distincts
4 :   si  $s \neq t$  alors
5 :      $S \leftarrow (S \setminus \{s, t\}) \cup \{s \odot t\}$            ▷ fusion
6 :   sinon
7 :      $S \leftarrow S \setminus \{s\}; \quad T \leftarrow T \cup \{s\}$    ▷  $s = t$  : sortie vers  $T$ 
8 :   fin si
9 : fin tant que
10 : retourner concaténation des chaînes de  $T$    ▷ sans aucune compression
```

- Quand le max de chevauchement est s avec elle-même, s **est retirée de l'ensemble** : plus d'imbrication.
- Fusions = arcs, chaînes figées = boucles : une **couverture de cycles** $\Rightarrow 4 \cdot OPT$.
- Prix : T concaténé **sans aucune compression**.

TGREEDY : la procédure

TGREEDY (Blum et al., section 4)

- 1 : exécuter la boucle de MGREEDY ▷ même T construit
- 2 : **retourner** GREEDY(T) ▷ au lieu de concaténer T tel quel : la seule différence

- MGREEDY laissait T sans compression ; TGREEDY récupère les recouvrements entre ses chaînes.
- Récupérer T ne rouvre pas le problème :
 $|\text{TGREEDY}(S)| \leq 3 \cdot \text{OPT}.$

TGREEDY en action

MGREEDY :
concat T

TACGGA GGATCA CATTA

⇒ 18

TGREEDY :
GREEDY(T)

T	A	C	G	G	A
---	---	---	---	---	---

G	G	A	T	C	A
---	---	---	---	---	---

$$chev = 3$$

C	A	T	T	A	A
---	---	---	---	---	---

$$\text{chev} = 2 \Rightarrow 13$$

- Mêmes blocs T , même phase gloutonne : **13** caractères au lieu de **18**.

Exemple construit pour la démo ; il n'apparaît pas dans le papier (Blum et al.).

Les trois gloutons sur S_0

étape	S	T	argmax (<i>chev</i>)
GREEDY			
1	{alfalfa,alpha,ate,half,lethal}	—	(half,alfalfa) 3
2	{alpha,ate,halfalfa,lethal}	—	(lethal,halfalfa) 3
3	{alpha,ate,lethalfalfa}	—	(alpha,ate) 1
4	{alphate,lethalfalfa}	—	(lethalfalfa,alphate) 1
$\Rightarrow$ lethalfalfalphate : 17			
MGREEDY			
1	{alfalfa,alpha,ate,half,lethal}	$\emptyset$	(alfalfa,alfalfa) 4 $\rightarrow T$
2	{alpha,ate,half,lethal}	{alfalfa}	(lethal,half) 3
3	{alpha,ate,lethalf}	{alfalfa}	(alpha,alpha) 1 $\rightarrow T$
4	{ate,lethalf}	{alfalfa,alpha}	(ate,ate) 0 $\rightarrow T$
5	{lethalf}	{alfalfa,alpha,ate}	(lethalf,lethalf) 0 $\rightarrow T$
$\Rightarrow$ concat(T) = alfalfaalphaatelethalf : 22			
TGREEDY phase 1 = MGREEDY $\rightarrow$ même T = {alfalfa,alpha,ate,lethalf}			
1	{alfalfa,alpha,ate,lethalf}	—	(lethalf,alfalfa) 3
2	{alpha,ate,lethalfalfa}	—	(alpha,ate) 1
3	{alphate,lethalfalfa}	—	(lethalfalfa,alphate) 1
$\Rightarrow$ GREEDY(T) = lethalfalfalphate : 17			

T au début de l'étape; $\rightarrow T$: la chaîne rejoint T .

- Blum, Jiang, Li, Tromp, Yannakakis. *Linear Approximation of Shortest Superstrings*. STOC 1991 / JACM 41(4), 1994. [PDF dans support/]
- Englert, Matsakis, Veselý. *Approximation Guarantees for Shortest Superstrings : Simpler and Better*. ISAAC 2023.
- Gallant, Maier, Storer. *On Finding Minimal Length Superstrings*. JCSS 20(1), 1980.
- Mucha. *Lyndon Words and Short Superstrings*. SODA 2013.
- Jones & Pevzner, *An Introduction to Bioinformatics Algorithms*, p. 268–275 (DNA sequencing).