

Démo 2 : alignement de séquences

Programmation dynamique : distance d'édition, global et local

Émeric Laberge

IFT3295, vendredi 18 septembre 2026

1. Le score d'un alignement : pénalité de gaps
2. Exercice 1 : la table de programmation dynamique (distance d'édition)
3. Exercices 2 et 3 : similarité, alignement local vs global
4. Exercices 4 et 5 : recherche de motif, plus longue sous-séquence commune

Le score d'un alignement : pénalité de gaps

Alignement A

match +1, mismatch -1, gap -1

S: ACGTTTACG-TAC-T

T: ACC---ACGCTAGCT

Score de A pour chaque pondération des gaps :

1. constante (chaque *colonne* de gap coûte 1)
2. linéaire (chaque *indel* coûte 1)
3. affine (ouverture -1 par bloc, extension $\sigma = -0,5$ par indel)
4. convexe (bloc de longueur t : $-1 - \ln t$)

Le score d'un alignement : pénalité de gaps

Alignement A

match +1, mismatch -1, gap -1

S: ACGTTTACG-TAC-T

T: ACC---ACGCTAGCT

Score de A pour chaque pondération des gaps :

1. constante (chaque *colonne* de gap coûte 1)
2. linéaire (chaque *indel* coûte 1)
3. affine (ouverture -1 par bloc, extension $\sigma = -0,5$ par indel)
4. convexe (bloc de longueur t : $-1 - \ln t$)

A contient **8 matches**, **2 mismatches**, **3 blocs de gaps** totalisant **5 indels**.

Le score d'un alignement : pénalité de gaps

Alignement A

match +1, mismatch -1, gap -1

S: ACGTTTACG-TAC-T

T: ACC---ACGCTAGCT

Score de A pour chaque pondération des gaps :

1. constante (chaque *colonne* de gap coûte 1)
2. linéaire (chaque *indel* coûte 1)
3. affine (ouverture -1 par bloc, extension $\sigma = -0,5$ par indel)
4. convexe (bloc de longueur t : $-1 - \ln t$)

A contient **8 matches**, **2 mismatches**, **3 blocs de gaps** totalisant **5 indels**.

constante **3** linéaire **1** affine **0,5** convexe $\approx$ **1,90**

Exercice 1 : alignement avec distance d'édition

Distance d'édition (Levenshtein, 1966)

$D(S, T)$ = nombre minimal de **substitutions** et d'**indels** pour transformer S en T .

- Comparer position par position (distance de *Hamming*) interdit tout décalage : une seule insertion décale toute la fin de la séquence.
- En autorisant quelques indels bien placés, les séquences se recollent : c'est la **distance d'édition**.
- Calculer $D(S, T)$ n'est pas trivial → **programmation dynamique** (Bellman) : résoudre tous les sous-problèmes sur les *préfixes*, une seule fois chacun, dans une table.

Exercice 1 (a) : les équations de récurrence

Programmation dynamique, distance d'édition

$D(i, j)$ = distance entre $S[1..i]$ (les i premiers caractères) et $T[1..j]$.

$$D(i, j) = \min \begin{cases} D(i-1, j) + 1 & s_i \text{ supprimé (gap dans } T) \\ D(i, j-1) + 1 & t_j \text{ inséré (gap dans } S) \\ D(i-1, j-1) + [s_i \neq t_j] & s_i \text{ aligné avec } t_j \end{cases}$$

Conditions initiales : $D(i, 0) = i$ et $D(0, j) = j$.

- Pourquoi c'est correct : la dernière colonne d'un alignement optimal ne peut être que l'un des trois cas.

Exercice 1 (b) : construire la table

$S = \text{CTGCGACA}$ en lignes ($n = 8$), $T = \text{TGCAAG}$ en colonnes ($m = 6$). Une case = le minimum de ses trois voisines : haut +1, gauche +1, diagonale +0 (match) ou +1 (mismatch). Exemple $D(1,1) : \text{C vs T} \rightarrow \min(2, 2, 0 + 1) = 1$.

D		T	G	C	A	A	G
C							
T							
G							
C							
G							
A							
C							
A							

Exercice 1 (b) : construire la table

$S = \text{CTGCGACA}$ en lignes ($n = 8$), $T = \text{TGCAAG}$ en colonnes ($m = 6$). Une case = le minimum de ses trois voisines : haut +1, gauche +1, diagonale +0 (match) ou +1 (mismatch). Exemple $D(1,1) : \text{C vs T} \rightarrow \min(2, 2, 0 + 1) = 1$.

D		T	G	C	A	A	G
	0 ←	1 ←	2 ←	3 ←	4 ←	5 ←	6
C							
T							
G							
C							
G							
A							
C							
A							

Exercice 1 (b) : construire la table

$S = \text{CTGCGACA}$ en lignes ($n = 8$), $T = \text{TGCAAG}$ en colonnes ($m = 6$). Une case = le minimum de ses trois voisines : haut +1, gauche +1, diagonale +0 (match) ou +1 (mismatch). Exemple $D(1,1)$: C vs T $\rightarrow \min(2, 2, 0 + 1) = 1$.

D		T	G	C	A	A	G
	0 ← 1 ← 2 ← 3 ← 4 ← 5 ← 6						
C	↑ 1						
T	↑ 2						
G	↑ 3						
C	↑ 4						
G	↑ 5						
A	↑ 6						
C	↑ 7						
A	↑ 8						

Exercice 1 (b) : construire la table

$S = \text{CTGCGACA}$ en lignes ($n = 8$), $T = \text{TGCAAG}$ en colonnes ($m = 6$). Une case = le minimum de ses trois voisines : haut +1, gauche +1, diagonale +0 (match) ou +1 (mismatch). Exemple $D(1,1)$: C vs T $\rightarrow \min(2, 2, 0 + 1) = 1$.

D		T	G	C	A	A	G
	0	← 1	← 2	← 3	← 4	← 5	← 6
C	↑ 1	↖ 1	← 2	↖ 2	← 3	← 4	← 5
T	↑ 2						
G	↑ 3						
C	↑ 4						
G	↑ 5						
A	↑ 6						
C	↑ 7						
A	↑ 8						

Exercice 1 (b) : construire la table

$S = \text{CTGCGACA}$ en lignes ($n = 8$), $T = \text{TGCAAG}$ en colonnes ($m = 6$). Une case = le minimum de ses trois voisines : haut +1, gauche +1, diagonale +0 (match) ou +1 (mismatch). Exemple $D(1,1)$: C vs T $\rightarrow \min(2, 2, 0 + 1) = 1$.

D		T	G	C	A	A	G
	0	1	2	3	4	5	6
C	1	1	2	2	3	4	5
T	2	1	2	3	3	4	5
G	3						
C	4						
G	5						
A	6						
C	7						
A	8						

Exercice 1 (b) : construire la table

$S = \text{CTGCGACA}$ en lignes ($n = 8$), $T = \text{TGCAAG}$ en colonnes ($m = 6$). Une case = le minimum de ses trois voisines : haut +1, gauche +1, diagonale +0 (match) ou +1 (mismatch). Exemple $D(1,1)$: C vs T $\rightarrow \min(2, 2, 0 + 1) = 1$.

D		T	G	C	A	A	G
	0	1	2	3	4	5	6
C	1	1	2	2	3	4	5
T	2	1	2	3	3	4	5
G	3	2	1	2	3	4	4
C	4						
G	5						
A	6						
C	7						
A	8						

Exercice 1 (b) : construire la table

$S = \text{CTGCGACA}$ en lignes ($n = 8$), $T = \text{TGCAAG}$ en colonnes ($m = 6$). Une case = le minimum de ses trois voisines : haut +1, gauche +1, diagonale +0 (match) ou +1 (mismatch). Exemple $D(1,1)$: C vs T $\rightarrow \min(2, 2, 0 + 1) = 1$.

D		T	G	C	A	A	G
	0	1	2	3	4	5	6
C	1	1	2	2	3	4	5
T	2	1	2	3	3	4	5
G	3	2	1	2	3	4	4
C	4	3	2	1	2	3	4
G	5						
A	6						
C	7						
A	8						

Exercice 1 (b) : construire la table

$S = \text{CTGCGACA}$ en lignes ($n = 8$), $T = \text{TGCAAG}$ en colonnes ($m = 6$). Une case = le minimum de ses trois voisines : haut +1, gauche +1, diagonale +0 (match) ou +1 (mismatch). Exemple $D(1,1)$: C vs T $\rightarrow \min(2, 2, 0 + 1) = 1$.

D		T	G	C	A	A	G
	0	1	2	3	4	5	6
C	1	1	2	2	3	4	5
T	2	1	2	3	3	4	5
G	3	2	1	2	3	4	4
C	4	3	2	1	2	3	4
G	5	4	3	2	2	3	3
A	6						
C	7						
A	8						

Exercice 1 (b) : construire la table

$S = \text{CTGCGACA}$ en lignes ($n = 8$), $T = \text{TGCAAG}$ en colonnes ($m = 6$). Une case = le minimum de ses trois voisines : haut +1, gauche +1, diagonale +0 (match) ou +1 (mismatch). Exemple $D(1,1)$: C vs T $\rightarrow \min(2, 2, 0 + 1) = 1$.

D		T	G	C	A	A	G
	0	1	2	3	4	5	6
C	1	1	2	2	3	4	5
T	2	1	2	3	3	4	5
G	3	2	1	2	3	4	4
C	4	3	2	1	2	3	4
G	5	4	3	2	2	3	3
A	6	5	4	3	2	2	3
C	7						
A	8						

Exercice 1 (b) : construire la table

$S = \text{CTGCGACA}$ en lignes ($n = 8$), $T = \text{TGCAAG}$ en colonnes ($m = 6$). Une case = le minimum de ses trois voisines : haut +1, gauche +1, diagonale +0 (match) ou +1 (mismatch). Exemple $D(1,1)$: C vs T $\rightarrow \min(2, 2, 0 + 1) = 1$.

D		T	G	C	A	A	G
	0	1	2	3	4	5	6
C	1	1	2	2	3	4	5
T	2	1	2	3	3	4	5
G	3	2	1	2	3	4	4
C	4	3	2	1	2	3	4
G	5	4	3	2	2	3	3
A	6	5	4	3	2	2	3
C	7	6	5	4	3	3	3
A	8						

Exercice 1 (b) : construire la table

$S = \text{CTGCGACA}$ en lignes ($n = 8$), $T = \text{TGCAAG}$ en colonnes ($m = 6$). Une case = le minimum de ses trois voisines : haut +1, gauche +1, diagonale +0 (match) ou +1 (mismatch). Exemple $D(1,1)$: C vs T $\rightarrow \min(2, 2, 0 + 1) = 1$.

D		T	G	C	A	A	G
	0	1	2	3	4	5	6
C	1	1	2	2	3	4	5
T	2	1	2	3	3	4	5
G	3	2	1	2	3	4	4
C	4	3	2	1	2	3	4
G	5	4	3	2	2	3	3
A	6	5	4	3	2	2	3
C	7	6	5	4	3	3	3
A	8	7	6	5	4	3	4

Exercice 1 (c) : retrouver un alignement optimal

<i>D</i>		T	G	C	A	A	G
	0 ← 1 ← 2 ← 3 ← 4 ← 5 ← 6						
C	↑ 1	← 1	← 2	← 2	← 3	← 4	← 5
T	↑ 2	↑ 1	← 2	← 3	← 3	← 4	← 5
G	↑ 3	↑ 2	↑ 1	← 2	← 3	← 4	4
C	↑ 4	↑ 3	↑ 2	↑ 1	← 2	← 3	← 4
G	↑ 5	↑ 4	↑ 3	↑ 2	↑ 2	← 3	3
A	↑ 6	↑ 5	↑ 4	↑ 3	↑ 2	↑ 2	← 3
C	↑ 7	↑ 6	↑ 5	↑ 4	↑ 3	↑ 3	← 3
A	↑ 8	↑ 7	↑ 6	↑ 5	↑ 4	↑ 3	← 4

Exercice 1 (c) : retrouver un alignement optimal

D		T	G	C	A	A	G
	0	1	2	3	4	5	6
C	1	1	2	2	3	4	5
T	2	1	2	3	3	4	5
G	3	2	1	2	3	4	4
C	4	3	2	1	2	3	4
G	5	4	3	2	2	3	3
A	6	5	4	3	2	2	3
C	7	6	5	4	3	3	3
A	8	7	6	5	4	3	4

$D(8, 6) = 4$: deux délétions et deux substitutions (la case orange, en bas à droite).

Exercice 1 (c) : retrouver un alignement optimal

D		T	G	C	A	A	G
	0	1	2	3	4	5	6
C	1	1	2	2	3	4	5
T	2	1	2	3	3	4	5
G	3	2	1	2	3	4	4
C	4	3	2	1	2	3	4
G	5	4	3	2	2	3	3
A	6	5	4	3	2	2	3
C	7	6	5	4	3	3	3
A	8	7	6	5	4	3	4

$D(8, 6) = 4$: deux délétions et deux substitutions (la case orange, en bas à droite).

A
G

On part de la case finale : sa flèche (rouge) et ses alternatives (bleu) donnent la dernière colonne.

Exercice 1 (c) : retrouver un alignement optimal

D		T	G	C	A	A	G
	0	1	2	3	4	5	6
C	1	1	2	2	3	4	5
T	2	1	2	3	3	4	5
G	3	2	1	2	3	4	4
C	4	3	2	1	2	3	4
G	5	4	3	2	2	3	3
A	6	5	4	3	2	2	3
C	7	6	5	4	3	3	3
A	8	7	6	5	4	3	4

$D(8, 6) = 4$: deux délétions et deux substitutions (la case orange, en bas à droite).

C	A
A	G

On remonte d'un pas de plus : les flèches atteintes en deux flèches et les colonnes correspondantes.

Exercice 1 (c) : retrouver un alignement optimal

D		T	G	C	A	A	G
	0	1	2	3	4	5	6
C	1	1	2	2	3	4	5
T	2	1	2	3	3	4	5
G	3	2	1	2	3	4	4
C	4	3	2	1	2	3	4
G	5	4	3	2	2	3	3
A	6	5	4	3	2	2	3
C	7	6	5	4	3	3	3
A	8	7	6	5	4	3	4

$D(8, 6) = 4$: deux délétions et deux substitutions (la case orange, en bas à droite).

C	T	G	C	G	A	C	A
-	T	G	C	-	A	A	G

- **Traceback** : de (n, m) vers $(0, 0)$, en suivant les voisins qui expliquent la valeur ; chaque pas donne une colonne de l'alignement.
- **Rouge gras** : le chemin suivi.
Bleu : les autres parcours optimaux.

Exercice 1 (d) : complexité

- **Temps** : la table a $m \times n$ cases ($m = |T|$, $n = |S|$) et chaque case s'obtient en temps constant (ses trois voisines et une comparaison) $\rightarrow \mathcal{O}(mn)$.
- **Espace** : $\mathcal{O}(mn)$ pour garder la table, dont le traceback a besoin.
- Le traceback lui-même est en $\mathcal{O}(m + n)$: négligeable devant le remplissage.

Exercice 2 : similarité plutôt qu'une distance

Similarité : Needleman–Wunsch (1970)

$\delta(a, b)$: score d'appariement (match $+\varepsilon$, mismatch $-\mu$, gap $-\sigma$; matrices BLOSUM pour les protéines).

$$V(i, j) = \max \begin{cases} V(i-1, j) + \delta(s_i, -) \\ V(i, j-1) + \delta(-, t_j) \\ V(i-1, j-1) + \delta(s_i, t_j) \end{cases} \quad \begin{aligned} V(i, 0) &= \sum_{k \leq i} \delta(s_k, -) \\ V(0, j) &= \sum_{k \leq j} \delta(-, t_k) \end{aligned}$$

- Deux changements par rapport à la distance : **max** au lieu de **min**, et des conditions initiales *cumulées* (chaque gap de bord paie son score).

Exercice 3 (a) : local ou global ?

- Quelle est la différence entre un alignement **local** et un alignement **global** ?

Exercice 3 (a) : local ou global ?

- Quelle est la différence entre un alignement **local** et un alignement **global** ?
- Un alignement **global** est un alignement des deux séquences *au complet* : les deux séquences entières, gaps compris.
- Un alignement **local** est l'alignement d'un *facteur* d'une séquence avec un facteur de l'autre : seules les **régions conservées** sont comparées, le reste est ignoré.
- Cas d'usage : global pour des séquences homologues de longueur comparable, local pour des séquences divergentes où seul un domaine ou un motif est partagé.

Exercice 3 (b) : la distance d'édition en local

- Dans le cas d'un alignement **local**, la distance d'édition est-elle utile ?

Exercice 3 (b) : la distance d'édition en local

- Dans le cas d'un alignement **local**, la distance d'édition est-elle utile ?
- **Non** : il existe toujours un alignement local « vide », de distance 0, quelles que soient les séquences en entrée.
- Une distance cherche à *minimiser* les différences : le score 0 de l'alignement vide serait donc toujours atteignable, et la table ne pourrait jamais descendre sous 0.
- En local, il faut au contraire *maximiser* une ressemblance et pouvoir repartir de zéro : c'est le **parcours gratuit** de Smith–Waterman.

Exercice 3 (c) : Smith–Waterman et Needleman–Wunsch

Smith–Waterman (1981)

$$V(i, j) = \max \begin{cases} 0 & \text{parcours gratuit} \\ V(i-1, j) + \delta(s_i, -) \\ V(i, j-1) + \delta(-, t_j) \\ V(i-1, j-1) + \delta(s_i, t_j) \end{cases}$$

Conditions initiales : $V(i, 0) = V(0, j) = 0$.

- Un seul ingrédient nouveau par rapport à Needleman–Wunsch : le **parcours gratuit** (le 0 de la récurrence, et des bords à 0 au lieu des scores cumulés).
- On lit le **maximum** de la table, puis on suit les pointeurs jusqu'à un 0.

Exercice 4 : recherche approximative d'un motif

Chercher $P = \text{GCG}$ dans $T = \text{CTGCGCACA}$ (à k erreurs près)

Scores : match 0, mismatch 1, gap 1.

Conditions initiales : $D(0, j) = 0$ (départ libre dans T), $D(i, 0) = i$ (P s'aligne en entier).

Réurrence : $D(i, j) =$

$\min\{ D(i, j-1) + \delta(-, t_j), D(i-1, j) + \delta(s_i, -), D(i-1, j-1) + \delta(s_i, t_j) \}.$

D		C	T	G	C	G	C	A	C	A
G										
C										
G										

Exercice 4 : recherche approximative d'un motif

Chercher $P = \text{GCG}$ dans $T = \text{CTGCGCACA}$ (à k erreurs près)

Scores : match 0, mismatch 1, gap 1.

Conditions initiales : $D(0, j) = 0$ (départ libre dans T), $D(i, 0) = i$ (P s'aligne en entier).

Réurrence : $D(i, j) =$

$\min\{ D(i, j-1) + \delta(-, t_j), D(i-1, j) + \delta(s_i, -), D(i-1, j-1) + \delta(s_i, t_j) \}.$

D		C	T	G	C	G	C	A	C	A
	0	0	0	0	0	0	0	0	0	0
G										
C										
G										

Exercice 4 : recherche approximative d'un motif

Chercher $P = \text{GCG}$ dans $T = \text{CTGCGCACA}$ (à k erreurs près)

Scores : match 0, mismatch 1, gap 1.

Conditions initiales : $D(0, j) = 0$ (départ libre dans T), $D(i, 0) = i$ (P s'aligne en entier).

Réurrence : $D(i, j) =$

$\min\{ D(i, j-1) + \delta(-, t_j), D(i-1, j) + \delta(s_i, -), D(i-1, j-1) + \delta(s_i, t_j) \}.$

D		C	T	G	C	G	C	A	C	A
	0	0	0	0	0	0	0	0	0	0
G	1									
C	2									
G	3									

Exercice 4 : recherche approximative d'un motif

Chercher $P = \text{GCG}$ dans $T = \text{CTGCGCACA}$ (à k erreurs près)

Scores : match 0, mismatch 1, gap 1.

Conditions initiales : $D(0, j) = 0$ (départ libre dans T), $D(i, 0) = i$ (P s'aligne en entier).

Récurrance : $D(i, j) =$

$\min\{ D(i, j-1) + \delta(-, t_j), D(i-1, j) + \delta(s_i, -), D(i-1, j-1) + \delta(s_i, t_j) \}.$

D		C	T	G	C	G	C	A	C	A
	0	0	0	0	0	0	0	0	0	0
G	1	1	1	0	1	0	1	1	1	1
C	2									
G	3									

Exercice 4 : recherche approximative d'un motif

Chercher $P = \text{GCG}$ dans $T = \text{CTGCGCACA}$ (à k erreurs près)

Scores : match 0, mismatch 1, gap 1.

Conditions initiales : $D(0, j) = 0$ (départ libre dans T), $D(i, 0) = i$ (P s'aligne en entier).

Récurrance : $D(i, j) =$

$\min\{ D(i, j-1) + \delta(-, t_j), D(i-1, j) + \delta(s_i, -), D(i-1, j-1) + \delta(s_i, t_j) \}.$

D		C	T	G	C	G	C	A	C	A
	0	0	0	0	0	0	0	0	0	0
G	1	1	1	0	1	0	1	1	1	1
C	2	1	2	1	0	1	0	1	1	2
G	3									

Exercice 4 : recherche approximative d'un motif

Chercher $P = \text{GCG}$ dans $T = \text{CTGCGCACA}$ (à k erreurs près)

Scores : match 0, mismatch 1, gap 1.

Conditions initiales : $D(0, j) = 0$ (départ libre dans T), $D(i, 0) = i$ (P s'aligne en entier).

Récurrance : $D(i, j) =$

$\min\{ D(i, j-1) + \delta(-, t_j), D(i-1, j) + \delta(s_i, -), D(i-1, j-1) + \delta(s_i, t_j) \}.$

D		C	T	G	C	G	C	A	C	A
	0	0	0	0	0	0	0	0	0	0
G	1	1	1	0	1	0	1	1	1	1
C	2	1	2	1	0	1	0	1	1	2
G	3	2	2	2	1	0	1	1	2	2

Dernière ligne : un 0 ($\leq k$) en colonne $j =$ occurrence (approximative) de P **finissant à la position j** de T . Ici $j = 5$: $T[3..5] = \text{GCG}$, occurrence exacte.

Exercice 5 : plus longue sous-séquence commune (LCS)

D		T	G	C	A	A	G
C							
T							
G							
C							
G							
A							
C							
A							

- Sous-séquence = caractères **dans l'ordre**, pas forcément contigus.
- Global : match +1, gap 0, mismatch $-\infty$, conditions initiales $V(i, 0) = V(0, j) = 0$ et $V(i, j) = \max\{ V(i, j-1) + \delta(-, t_j), V(i-1, j) + \delta(s_i, -), V(i-1, j-1) + \delta(s_i, t_j) \}$; seuls les matches survivent, $V(n, m) = |\text{LCS}|$.

Exercice 5 : plus longue sous-séquence commune (LCS)

D		T	G	C	A	A	G
	0	← 0	← 0	← 0	← 0	← 0	← 0
C							
T							
G							
C							
G							
A							
C							
A							

- Sous-séquence = caractères **dans l'ordre**, pas forcément contigus.
- Global : match +1, gap 0, mismatch $-\infty$, conditions initiales $V(i, 0) = V(0, j) = 0$ et $V(i, j) = \max\{ V(i, j-1) + \delta(-, t_j), V(i-1, j) + \delta(s_i, -), V(i-1, j-1) + \delta(s_i, t_j) \}$; seuls les matches survivent, $V(n, m) = |\text{LCS}|$.

Exercice 5 : plus longue sous-séquence commune (LCS)

D		T	G	C	A	A	G
	0	← 0	← 0	← 0	← 0	← 0	← 0
C	↑ 0						
T	↑ 0						
G	↑ 0						
C	↑ 0						
G	↑ 0						
A	↑ 0						
C	↑ 0						
A	↑ 0						

- Sous-séquence = caractères **dans l'ordre**, pas forcément contigus.
- Global : match +1, gap 0, mismatch $-\infty$, conditions initiales $V(i, 0) = V(0, j) = 0$ et $V(i, j) = \max\{ V(i, j-1) + \delta(-, t_j), V(i-1, j) + \delta(s_i, -), V(i-1, j-1) + \delta(s_i, t_j) \}$; seuls les matches survivent, $V(n, m) = |\text{LCS}|$.

Exercice 5 : plus longue sous-séquence commune (LCS)

D		T	G	C	A	A	G
	0	← 0	← 0	← 0	← 0	← 0	← 0
C	0	← 0	← 0	1	← 1	← 1	← 1
T	0						
G	0						
C	0						
G	0						
A	0						
C	0						
A	0						

- Sous-séquence = caractères **dans l'ordre**, pas forcément contigus.
- Global : match +1, gap 0, mismatch $-\infty$, conditions initiales $V(i, 0) = V(0, j) = 0$ et $V(i, j) = \max\{ V(i, j-1) + \delta(-, t_j), V(i-1, j) + \delta(s_i, -), V(i-1, j-1) + \delta(s_i, t_j) \}$; seuls les matches survivent, $V(n, m) = |\text{LCS}|$.

Exercice 5 : plus longue sous-séquence commune (LCS)

D		T	G	C	A	A	G
	0	← 0	← 0	← 0	← 0	← 0	← 0
C	0	← 0	← 0	1	← 1	← 1	← 1
T	0	1	← 1	← 1	← 1	← 1	← 1
G	0						
C	0						
G	0						
A	0						
C	0						
A	0						

- Sous-séquence = caractères **dans l'ordre**, pas forcément contigus.
- Global : match +1, gap 0, mismatch $-\infty$, conditions initiales $V(i, 0) = V(0, j) = 0$ et $V(i, j) = \max\{ V(i, j-1) + \delta(-, t_j), V(i-1, j) + \delta(s_i, -), V(i-1, j-1) + \delta(s_i, t_j) \}$; seuls les matches survivent, $V(n, m) = |\text{LCS}|$.

Exercice 5 : plus longue sous-séquence commune (LCS)

D		T	G	C	A	A	G
	0	← 0	← 0	← 0	← 0	← 0	← 0
C	0	← 0	← 0	1	← 1	← 1	← 1
T	0	1	← 1	← 1	← 1	← 1	← 1
G	0	1	2	← 2	← 2	← 2	← 2
C	0						
G	0						
A	0						
C	0						
A	0						

- Sous-séquence = caractères **dans l'ordre**, pas forcément contigus.
- Global : match +1, gap 0, mismatch $-\infty$, conditions initiales $V(i, 0) = V(0, j) = 0$ et $V(i, j) = \max\{ V(i, j-1) + \delta(-, t_j), V(i-1, j) + \delta(s_i, -), V(i-1, j-1) + \delta(s_i, t_j) \}$; seuls les matches survivent, $V(n, m) = |\text{LCS}|$.

Exercice 5 : plus longue sous-séquence commune (LCS)

D		T	G	C	A	A	G
	0	0	0	0	0	0	0
C	0	0	0	1	1	1	1
T	0	1	1	1	1	1	1
G	0	1	2	2	2	2	2
C	0	1	2	3	3	3	3
G	0						
A	0						
C	0						
A	0						

- Sous-séquence = caractères **dans l'ordre**, pas forcément contigus.
- Global : match +1, gap 0, mismatch $-\infty$, conditions initiales $V(i, 0) = V(0, j) = 0$ et $V(i, j) = \max\{ V(i, j-1) + \delta(-, t_j), V(i-1, j) + \delta(s_i, -), V(i-1, j-1) + \delta(s_i, t_j) \}$; seuls les matches survivent, $V(n, m) = |\text{LCS}|$.

Exercice 5 : plus longue sous-séquence commune (LCS)

D		T	G	C	A	A	G
	0	0	0	0	0	0	0
C	0	0	0	1	1	1	1
T	0	1	1	1	1	1	1
G	0	1	2	2	2	2	2
C	0	1	2	3	3	3	3
G	0	1	2	3	3	3	4
A	0						
C	0						
A	0						

- Sous-séquence = caractères **dans l'ordre**, pas forcément contigus.
- Global : match +1, gap 0, mismatch $-\infty$, conditions initiales $V(i, 0) = V(0, j) = 0$ et $V(i, j) = \max\{ V(i, j-1) + \delta(-, t_j), V(i-1, j) + \delta(s_i, -), V(i-1, j-1) + \delta(s_i, t_j) \}$; seuls les matches survivent, $V(n, m) = |\text{LCS}|$.

Exercice 5 : plus longue sous-séquence commune (LCS)

D		T	G	C	A	A	G
	0	0	0	0	0	0	0
C	0	0	0	1	1	1	1
T	0	1	1	1	1	1	1
G	0	1	2	2	2	2	2
C	0	1	2	3	3	3	3
G	0	1	2	3	3	3	4
A	0	1	2	3	4	4	4
C	0						
A	0						

- Sous-séquence = caractères **dans l'ordre**, pas forcément contigus.
- Global : match +1, gap 0, mismatch $-\infty$, conditions initiales $V(i, 0) = V(0, j) = 0$ et $V(i, j) = \max\{ V(i, j-1) + \delta(-, t_j), V(i-1, j) + \delta(s_i, -), V(i-1, j-1) + \delta(s_i, t_j) \}$; seuls les matches survivent, $V(n, m) = |\text{LCS}|$.

Exercice 5 : plus longue sous-séquence commune (LCS)

D		T	G	C	A	A	G
	0	0	0	0	0	0	0
C	0	0	0	1	1	1	1
T	0	1	1	1	1	1	1
G	0	1	2	2	2	2	2
C	0	1	2	3	3	3	3
G	0	1	2	3	3	3	4
A	0	1	2	3	4	4	4
C	0	1	2	3	4	4	4
A	0						

- Sous-séquence = caractères **dans l'ordre**, pas forcément contigus.
- Global : match +1, gap 0, mismatch $-\infty$, conditions initiales $V(i, 0) = V(0, j) = 0$ et $V(i, j) = \max\{ V(i, j-1) + \delta(-, t_j), V(i-1, j) + \delta(s_i, -), V(i-1, j-1) + \delta(s_i, t_j) \}$; seuls les matches survivent, $V(n, m) = |\text{LCS}|$.

Exercice 5 : plus longue sous-séquence commune (LCS)

D		T	G	C	A	A	G
	0	← 0	← 0	← 0	← 0	← 0	← 0
C	0	← 0	← 0	↖ 1	← 1	← 1	← 1
T	0	↑ 1	← 1	← 1	← 1	← 1	← 1
G	0	↑ 1	↖ 2	← 2	← 2	← 2	← 2
C	0	↑ 1	↑ 2	↖ 3	← 3	← 3	← 3
G	0	↑ 1	↑ 2	↑ 3	← 3	← 3	↖ 4
A	0	↑ 1	↑ 2	↑ 3	↖ 4	← 4	← 4
C	0	↑ 1	↑ 2	↑ 3	↑ 4	← 4	← 4
A	0	↑ 1	↑ 2	↑ 3	↑ 4	↖ 5	↖ 5

- Sous-séquence = caractères **dans l'ordre**, pas forcément contigus.
- Global : match +1, gap 0, mismatch $-\infty$, conditions initiales $V(i, 0) = V(0, j) = 0$ et $V(i, j) = \max\{ V(i, j-1) + \delta(-, t_j), V(i-1, j) + \delta(s_i, -), V(i-1, j-1) + \delta(s_i, t_j) \}$; seuls les matches survivent, $V(n, m) = |\text{LCS}|$.

Pour $S = \text{CTGCGACA}$, $T = \text{TGCAAG}$:
 $V(8, 6) = \mathbf{5}$, avec TGCAA.

Variante contiguë (sous-chaîne commune) : alignement *local*, mismatch et gaps à $-\infty$.

Exercice 5 : retrouver la sous-séquence

D		T	G	C	A	A	G
	0	← 0	← 0	← 0	← 0	← 0	← 0
C	0	← 0	← 0	1	← 1	← 1	← 1
T	0	1	← 1	← 1	← 1	← 1	← 1
G	0	1	2	← 2	← 2	← 2	← 2
C	0	1	2	3	← 3	← 3	← 3
G	0	1	2	3	← 3	← 3	4
A	0	1	2	3	4	← 4	← 4
C	0	1	2	3	4	← 4	← 4
A	0	1	2	3	4	5	5

A
G

Exercice 5 : retrouver la sous-séquence

D		T	G	C	A	A	G
	0	0	0	0	0	0	0
C	0	0	0	1	1	1	1
T	0	1	1	1	1	1	1
G	0	1	2	2	2	2	2
C	0	1	2	3	3	3	3
G	0	1	2	3	3	3	4
A	0	1	2	3	4	4	4
C	0	1	2	3	4	4	4
A	0	1	2	3	4	5	5

C	A
A	G

Exercice 5 : retrouver la sous-séquence

D		T	G	C	A	A	G
	0	← 0	← 0	← 0	← 0	← 0	← 0
C	0	← 0	← 0	1	← 1	← 1	← 1
T	0	1	← 1	← 1	← 1	← 1	← 1
G	0	1	2	← 2	← 2	← 2	← 2
C	0	1	2	3	← 3	← 3	← 3
G	0	1	2	3	← 3	← 3	4
A	0	1	2	3	4	← 4	← 4
C	0	1	2	3	4	← 4	← 4
A	0	1	2	3	4	5	5

C	T	G	C	G	A	C	A
T	G	C	-	A	-	A	G

Pour $S = \text{CTGCGACA}$ et $T = \text{TGCAAG}$:
 $V(8,6) = \mathbf{5}$, avec TGCAA (les cinq appariements).

Une seule mécanique, cinq habillages

variante	optimise	conditions initiales	réponse
distance d'édition	min	$D(i, 0) = i, D(0, j) = j$	$D(n, m)$
global (NW)	max	$\sum \delta$ sur les bords	$V(n, m)$
local (SW)	max, +0	$V(i, 0) = V(0, j) = 0$	max de la table
recherche de motif	min	$D(0, j) = 0, D(i, 0) = i$	dernière ligne
LCS	max	0	$V(n, m)$

- Même table, mêmes trois voisins : seule change la fonction de score, les bords, et l'endroit d'où on lit la solution.

- Diapos du cours 2.1 — *Alignement de séquences biologiques* (N. El-Mabrouk), IFT3295.
- Jones & Pevzner, *An Introduction to Bioinformatics Algorithms*, ch. 6 (MIT Press, 2004).
- Levenshtein (1966); Needleman & Wunsch, *J. Mol. Biol.* 48 (1970); Smith & Waterman, *Adv. Appl. Math.* 2 (1981).
- Tables des diapos et du corrigé calculées par le style biotables (programmation dynamique en $\text{\LaTeX}$), donc rigoureusement les mêmes des deux côtés.