

IFT3295 — Démo 2

18 septembre 2026

Score d'un alignement de paire de séquences : pénalité de gaps

La pondération des gaps influence grandement l'alignement entre deux séquences. Certaines pondérations ont parfois plus de sens biologique que d'autres. Soit l'alignement A suivant :

S: ACGTTTACG-TAC-T

T: ACC---ACGCTAGCT

En considérant les scores suivants :

- match : $+1$
- mismatch : -1
- gap : -1

Donnez les scores de l'alignement A pour chacune des pondérations de gaps suivantes :

1. pondération constante
2. pondération linéaire (utiliser un score de -1 pour un indel)
3. pondération affine (utiliser une extension de gap $\sigma = -0,5$)
4. pondération convexe (utiliser un score $-1 - \ln(t)$)

Programmation dynamique et alignement de séquences

1. Alignement avec distance d'édition

- (a) Donner les équations de récurrences ainsi que les conditions initiales pour construire la table de programmation dynamique pour l'alignement entre deux séquences S et T avec la distance d'édition.

- (b) Construire la table de programmation dynamique pour les deux séquences suivantes : $S = \text{CTGCGACA}$ et $T = \text{TGCAAG}$.

D		T	G	C	A	A	G
C							
T							
G							
C							
G							
A							
C							
A							

- (c) Comment peut-on retrouver un alignement optimal de séquence à partir de la table ?

- (d) Donner la complexité de l'algorithme d'alignement de paires de séquences avec la distance d'édition.

2. Que faut-il changer si on désire utiliser la similarité plutôt qu'une mesure de distance pour aligner deux séquences ?

3. Alignement local vs. global
 - (a) Quelle est la différence entre un alignement local et un alignement global ?

 - (b) Dans le cas d'un alignement local, la distance d'édition est-elle utile ? Justifiez

 - (c) Donnez les conditions initiales et les équations de récurrence de l'alignement local Smith-Waterman et de l'alignement global Needleman-Wunsch.

4. Recherche de motif : chercher $P = \text{GCG}$ dans $T = \text{CTGCGCACA}$ (à k erreurs près).

(a) Quels scores d'appariement et quelles conditions initiales faut-il choisir pour laisser l'alignement libre sur T tout en alignant P en entier ?

(b) Donnez la relation de récurrence de la table $D(i, j)$.

(c) Construire la table de programmation dynamique.

D		C	T	G	C	G	C	A	C	A
G										
C										
G										

(d) Comment retrouve-t-on la position du motif dans T à partir de la table ? Où se termine l'occurrence exacte de **GCG** ?

5. Problème de la plus longue sous-séquence commune. On utilise les deux séquences suivantes : $S = \text{CTGCGACA}$ et $T = \text{TGCAAG}$.

(a) Qu'est-ce qu'une sous-séquence, par opposition à une sous-chaîne ? Donnez les scores d'appariement à utiliser.

(b) Donnez les conditions initiales et la relation de récurrence.

(c) Construire la table de programmation dynamique.

D		T	G	C	A	A	G
C							
T							
G							
C							
G							
A							
C							
A							

(d) Quelle est la taille de la plus longue sous-séquence commune, et quelle est cette sous-séquence ? Comment la retrouve-t-on dans la table ?